

Ressources gratuites pour une base de connaissance IA nutrition + musculation

TL;DR

- **Oui, il existe un écosystème complet de ressources gratuites et fiables.** Pour la nutrition, combinez **CIQUAL (ANSES)** en dump local (référence française validée scientifiquement) + **Open Food Facts** pour les produits emballés à code-barres + **USDA FoodData Central** en complément micronutriments. Pour la musculation, **Free Exercise DB** (JSON téléchargeable, domaine public) et/ou **wger** (API + dump, données CC-BY-SA) couvrent la bibliothèque d'exercices. Pour la partie scientifique, les **position stands de l'ISSN** (open access) et les **repères ANSES/PNNS** constituent un socle factuel citable.
- **Ne laissez jamais le LLM faire les calculs :** implémentez en code les formules déterministes (Mifflin-St Jeor pour BMR/TDEE, Epley/Brzycki pour le 1RM, ratios de macros ISSN/ANSES). Le LLM orchestre et explique, le code calcule.
- **Architecture recommandée :** chargez CIQUAL + Free Exercise DB localement dans Supabase (Postgres + pgvector) pour le RAG, réservez Open Food Facts à l'appel API par code-barres (avec cache), et injectez dans le prompt système un **résumé condensé** des recommandations ISSN/ANSES plutôt que les PDF entiers.

Key Findings

1. Bases de données nutritionnelles

- **CIQUAL (ANSES)** est LA référence française : sa dernière version compte **3 484 aliments et 74 constituants** (la version 2020 comptait 3 185 aliments et 67 constituants). Open data gratuit, téléchargeable en Excel/XML. Pas d'API officielle, mais des wrappers communautaires existent. ([Anses](#))
- **Open Food Facts** : base collaborative mondiale de **plus de 4 millions de produits** emballés à code-barres (le français est la 1re langue de la base, avec ~1,2 million de produits). API gratuite sans clé, excellente couverture France, mais qualité variable (crowdsourcé).
- **USDA FoodData Central** : **plus de 300 000 aliments** (dont ~8 000 Foundation Foods et ~380 000 Branded Foods). API gratuite (1 000 req/h avec clé), domaine public (CC0), mais orientée produits américains.

2. Bases d'exercices de musculation

- **Free Exercise DB** (yuhonas) : **plus de 800 exercices** en JSON, domaine public, téléchargeable directement depuis GitHub. ([GitHub](#))

- **wger** : ~700 exercices de base, API REST sans authentification pour la lecture, données CC-BY-SA, support français partiel, self-hostable.
- **ExerciseDB** : 1 300+ à 11 000+ exercices avec GIFs, tier gratuit auto-hébergé + tier RapidAPI payant.

3. Recommandations scientifiques

- **ISSN position stands** : tous en open access (protéines, nutrient timing, diètes/composition corporelle, créatine, caféine).
- **ANSES/PNNS** : repères français officiels (protéines, macros, fibres, sucres).

4. Calculateurs (formules à coder)

- **Mifflin-St Jeor** pour BMR/TDEE (formule la plus validée).
- **Epley/Brzycki** pour l'estimation du 1RM.

5. Projets GitHub d'inspiration

- Plusieurs projets RAG « coach IA » fitness/nutrition existent (alexeygrigorev/fitness-assistant, GeorgiosLympers/fitness_app, etc.).

Details

1. Bases de données nutritionnelles gratuites et ouvertes

CIQUAL — ANSES (LA référence pour la France)

- **Contenu** : dernière version = **3 484 aliments et 74 constituants** (glucides, sucres individuels, protéines, lipides, acides gras, sel, vitamines, minéraux, valeurs énergétiques). Teneurs pour 100 g de partie comestible. Une des tables les plus complètes d'Europe. (La version 2020 comptait 3 185 aliments / 67 constituants — vérifiez le millésime du fichier que vous téléchargez.) [Anses](#) [Anses](#)
- **Type d'accès** : Open data, gratuit. Téléchargeable en **Excel et XML** depuis le site CIQUAL (ciqual.anses.fr) et sur (data.gouv.fr). **Pas d'API REST officielle.** [Anses](#) [Anses](#)
- **Wrappers communautaires** :
 - github.com/kozlown/ciqual-table-api : API REST tierce (basée sur la version 2017), recherche par mot-clé et récupération des nutriments d'un aliment. [GitHub](#)
 - github.com/zzgael/ciqual-mcp : serveur **MCP (Model Context Protocol)** donnant un accès **SQL** à une base SQLite (~10 Mo, 3 185 aliments, 60+ nutriments, bilingue FR/EN, recherche full-text, mise à jour annuelle). **Particulièrement pertinent** pour un usage avec Claude Code : il expose une fonction d'exécution de requêtes SQL et se branche directement dans la config Claude Desktop. [GitHub](#) [Mcp](#)

- **Pertinence France** : maximale. Données représentatives des aliments consommés en France, noms en français. (Anses)
- **Recommandation** : c'est la source à charger localement (dump XML/Excel → Supabase) comme socle nutritionnel français fiable et citable. La structure relationnelle CIQUAL (fichiers (alim), (const), (compo), (sources)) est bien documentée et se transpose facilement en tables Postgres.

Open Food Facts

- **Contenu** : base collaborative de **plus de 4 millions de produits** alimentaires emballés du monde entier, avec code-barres, ingrédients, allergènes, valeurs nutritionnelles, Nutri-Score, groupe NOVA. Le **français est la première langue** de la base (~1,2 million de produits en français). (GitHub)
- **Type d'accès** : API REST gratuite, **sans clé API pour la lecture**. Endpoint produit : (`https://world.openfoodfacts.org/api/v2/product/{barcode}.json`). Sélection de champs possible ((`?fields=...`)) pour alléger les réponses. Données sous licence **ODbL** (attribution requise). (Open Food Facts) (Freeapihub)
- **Rate limits (doc officielle)** : **100 req/min/IP pour les GET produit, 10 req/min/IP pour les recherches, 2 req/min pour les requêtes de facettes**. Pas de limite sur l'écriture. Envoyez un (User-Agent) clair et mettez en cache. (dltHub) (Open Food Facts)
- **Exports en masse** : CSV (`(static.openfoodfacts.org/data/en.openfoodfacts.org.products.csv.gz)`), **Parquet** via Hugging Face ((`openfoodfacts/product-database`)), RDF, dump MongoDB — recommandés pour l'analytique plutôt que de marteler l'API live. (PublicAPI)
- **Pertinence France** : excellente (projet d'origine française, très forte couverture des produits vendus en France).
- **Limite** : données crowdsourcées, qualité/complétude variable selon les produits (le projet lui-même prévient qu'il n'y a « aucune garantie d'exactitude »). À utiliser pour les produits emballés à code-barres, en complément de CIQUAL pour les aliments bruts. (Open Food Facts)

USDA FoodData Central

- **Contenu** : **plus de 300 000 aliments** (Foundation Foods ~8 000, SR Legacy, Branded ~380 000, FNDDS survey), macros + micros complets, tailles de portions. Valeurs pour 100 g (SR Legacy/Foundation) ou par portion (Branded). (ChowAPI) (Selfhostednutrition)
- **Type d'accès** : API REST gratuite avec clé (signup gratuit sur (`fdc.nal.usda.gov/api-key-signup`) via `api.data.gov`). Dumps **CSV et JSON** téléchargeables (`(fdc.nal.usda.gov/download-datasets)`, ~6 Go). Format d'origine Access discontinué. (Selfhostednutrition) (USDA FoodData Central)

- **Rate limits : 1 000 req/h par IP** avec clé (le `DEMO_KEY` est limité à **30 req/h** et **50 req/jour**). En-têtes `X-RateLimit-Remaining` sur chaque réponse. Domaine public (CC0 1.0). `USDA FoodData Central + 3`
- **Pertinence France** : faible (orienté aliments et marques américains). Utile comme complément pour micronutriments détaillés ou aliments non couverts par CIQUAL.

Autres à connaître : base **CALNUT** dérivée de CIQUAL ; bases européennes **EuroFIR** (accès partiel payant).

2. Bases de connaissances / datasets d'exercices de musculation

Free Exercise DB (yuhonas/free-exercise-db) — le meilleur choix pour du RAG local

- **Contenu** : plus de 800 exercices en JSON, chacun avec : `name`, `force` (push/pull/static), `level` (beginner/intermediate/expert), `mechanic` (compound/isolation), `equipment`, `primaryMuscles`, `secondaryMuscles`, `instructions` (étapes détaillées), `category`, et images. `GitHub`
- **Type d'accès** : domaine public, téléchargeable directement (JSON individuels ou combiné) depuis GitHub. Images hébergées sur `raw.githubusercontent.com/yuhonas/free-exercise-db/main/exercises/`. Frontend de démo en Vue.js (`yuhonas.github.io/free-exercise-db`). `GitHub` `GitHub`
- **Format** : conforme à un JSON Schema ; tâche Makefile pour combiner en un seul fichier ou en NDJSON pour import PostgreSQL (idéal pour Supabase). `GitHub + 2`
- **Pertinence** : idéal comme base d'exercices à charger dans Supabase. Instructions en anglais uniquement.
- **Dérivés** : `joao-gugel/exercicios-bd-ptbr` (traduction PT-BR) et `exercemus/exercises` (fusion curée de plusieurs sources) montrent qu'une traduction FR par batch serait faisable. `GitHub` `GitHub`

wger (wger-project/wger)

- **Contenu** : ~700 exercices de base (davantage en comptant les traductions), avec catégories, muscles ciblés, équipement, images/vidéos. Tracker fitness + nutrition complet, self-hostable (Docker, Django). `GitHub`
- **Type d'accès** : API REST publique (`https://wger.de/api/v2/`), **lecture sans authentification** pour les exercices et ingrédients (auth requise seulement pour les objets utilisateur). Ajoutez `?status=2` pour n'obtenir que les exercices approuvés, `?language=X` pour filtrer par langue, `?limit=N` pour la pagination (20 par défaut). Endpoints riches : `/api/v2/exerciseinfo/`, `/api/v2/exercisebaseinfo/`, plus `/muscle/`, `/equipment/`, `/exercisecategory/`. **Aucune limite de débit publique documentée** (le projet recommande le self-hosting ou le dump pour un usage intensif). `Readthedocs + 2`

- **Dump/bulk** : commande `manage.py sync-exercises` (synchronise toute la base depuis wger.de), fixtures dans le repo GitHub, dump pré-généré pour les ingrédients. [Readthedocs](#) [Volkanpaksoy](#)
- **Licence** : code **AGPL-3.0** ; données d'exercices sous **Creative Commons (CC-BY-SA, 3.0 historiquement / 4.0 pour le catalogue courant)** — chaque exercice porte son propre champ `license`, à vérifier au cas par cas. [Github](#)
- **Support français** : oui (traductions communautaires via Weblate, le français fait partie des ~30 langues), mais **couverture FR partielle** (les exercices fréquents d'abord, fallback en anglais sinon). [Github](#) [Apify](#)
- **Nutrition** : base d'ingrédients **issue d'Open Food Facts** (dataset complet ~1 Go). [Github](#) [Readthedocs](#)
- **Pertinence** : excellente si vous voulez à la fois une base d'exercices ET un **modèle de schéma de données fitness/nutrition open source** à étudier pour structurer votre propre base.

ExerciseDB / alternatives API

- **ExerciseDB** : 1 300+ (open source) à 11 000+ (version complète) exercices avec **GIFs animés**, muscles ciblés, équipement, instructions pas-à-pas. Tier gratuit auto-hébergé (<https://oss.exercisedb.dev/api/v1/exercises>, ~1 500 exercices, GIFs 180p, **sans auth**) ; tier RapidAPI payant pour la HD et les visualisations musculaires. Attention : le tier RapidAPI gratuit historique était très limité (~10 req/jour selon des retours développeurs). [AscendAPI Docs](#) [DEV Community](#)
- **WorkoutX** : alternative avec 1 300-1 400+ exercices + GIFs, tier gratuit 500 req/mois, tarification transparente.
- **wrkout/exercises.json** : dataset JSON domaine public (ancêtre de Free Exercise DB). [Github](#)

Courbes de force / 1RM / tables de progression : il n'existe **pas de dataset ouvert standardisé** de « tables de force » (les standards type *Strength Level* sont propriétaires). Ces valeurs se calculent par formules (voir section 4) — c'est la bonne approche pour votre app.

3. Guides et recommandations scientifiques ouvertes

Position stands de l'ISSN (International Society of Sports Nutrition) — tous **open access** dans le *Journal of the ISSN* :

- **Protéines et exercice** (Jäger et al. 2017, DOI 10.1186/s12970-017-0177-8) — verbatim : « an overall daily protein intake in the range of **1.4-2.0 g protein/kg body weight/day** is sufficient for most exercising individuals » ; « Higher protein intakes (**2.3-3.1 g/kg/d**) may be needed to maximize the retention of lean body mass in resistance-trained subjects during hypocaloric periods » ; dose de 0,25 g/kg ou 20-40 g par prise ; 700-3000 mg de leucine par dose. [nih + 2](#)

- **Nutrient timing** (Kerksick et al. 2017, DOI 10.1186/s12970-017-0189-4) : glycogène maximisé par régime riche en glucides (8-12 g/kg/j) ; 20-40 g de protéines (0,25-0,40 g/kg) toutes les 3-4 h ; ~30-40 g de caséine avant le sommeil. (Taylor & Francis) (Taylor & Francis)
- **Diètes et composition corporelle** (Aragon et al. 2017, PMC5470183) : la perte de graisse est pilotée par un **déficit calorique soutenu** (déficit d'autant plus agressif que le % de masse grasse de départ est élevé ; perte plus lente = meilleure préservation de la masse maigre chez les sujets déjà secs) ; le gain de masse maigre par un **surplus calorique soutenu**. (nih)
- **Créatine** (Kreider et al. 2017, DOI 10.1186/s12970-017-0173-z) : la créatine monohydrate est « l'aide ergogénique nutritionnelle la plus efficace » pour la capacité en haute intensité et la masse maigre, profil de sécurité favorable. (Springer)
- **Caféine** (Guest et al. 2021, PMC7777221), **acides aminés essentiels** (Ferrando et al. 2023), beta-alanine, HMB, energy drinks, meal frequency — tous disponibles.

ANSES / PNNS (références françaises officielles) :

- **Références nutritionnelles 2016** (remplacent les ANC — la France est passée aux concepts RNP, AS, IR, LSS) : protéines besoin ~**0,83 g/kg/j** pour un adulte en bonne santé, soit **10-20 % de l'AET**, relevé à **1 g/kg/j après 65 ans** (prévention de la sarcopénie) ; glucides **40-55 % de l'AET** ; fibres **AS = 30 g/j** ; **maximum 100 g de sucres totaux/jour** (hors lactose et galactose). (AFDN + 3)
- **Repères de consommation PNNS 2017** : « aller vers » légumineuses ($\geq 2\times$ /semaine), céréales complètes, fruits/légumes (≥ 5 /jour), certaines huiles végétales ; « réduire » charcuterie, viande hors volaille, boissons sucrées. (Anses)
- Rapports PDF téléchargeables sur (anses.fr) (rapport NUT2012SA0103, HAL (anses-04314523)).

Attention : les recommandations ANSES visent la population générale / santé publique, pas spécifiquement la prise de masse / performance. Les position stands ISSN sont plus adaptés au contexte musculation. À combiner en le **précisant explicitement dans le prompt système** de chaque sous-agent.

4. Calculateurs / formules à implémenter en code (jamais via le LLM)

BMR — Mifflin-St Jeor (1990, la plus validée ; une revue systématique de Frankenfield 2005 l'a classée n°1 en précision) : (Calculatorian)

- Hommes : $\text{BMR} = 10 \times \text{poids(kg)} + 6,25 \times \text{taille(cm)} - 5 \times \text{âge} + 5$ (TDEE Calculator)
- Femmes : $\text{BMR} = 10 \times \text{poids(kg)} + 6,25 \times \text{taille(cm)} - 5 \times \text{âge} - 161$ (TDEE Calculator)

TDEE : $\text{TDEE} = \text{BMR} \times \text{facteur d'activité}$

- 1,2 sédentaire ; 1,375 léger (3-5×/sem léger) ; 1,55 modéré ; 1,725 très actif ; 1,9 extrême.

(NutriAdmin)

Alternative Katch-McArdle (si % masse grasse connu — **meilleure pour les sujets musclés**, car basée sur la masse maigre ; Mifflin-St Jeor sous-estime chez les athlètes musclés et surestime au-delà d'un IMC de 35). (Promealplan)

Objectifs caloriques : déficit ou surplus de **250-500 kcal/jour** selon l'objectif (~0,5 kg/semaine). (TDEE Calculator)

Répartition macros : protéines **1,6-2,2 g/kg** (musculature, cadre ISSN), reste réparti glucides/lipides selon préférences et bornes ANSES.

1RM (one-rep max) :

- **Epley** : $1RM = \text{poids} \times (1 + \text{reps}/30)$ (Coachway)
- **Brzycki** : $1RM = \text{poids} / (1,0278 - 0,0278 \times \text{reps})$ (équivalent à $\text{poids} \times 36 / (37 - \text{reps})$) (AJ Designer)
- Précision optimale à **1-10 reps** (Epley un peu plus haut, Brzycki un peu plus bas ; ils convergent à faibles reps). Recommandé : **moyenner les deux**. (Coachway)
- Dériver ensuite une **table de pourcentages (%1RM)** pour prescrire les charges (ex. 80 % → séries de 8 hypertrophie ; 90 % → séries de 3-4 force). (AJ Designer)

Ces formules sont simples, déterministes, et doivent **absolument être codées côté application** (TypeScript/Next.js) et exposées comme *tools* que le LLM appelle — pour éliminer les erreurs arithmétiques du LLM.

5. Projets GitHub d'inspiration (structuration RAG coach IA)

- [alexeygrigorev/fitness-assistant](#) : RAG fitness (LLM Zoomcamp), montre la **pondération par champ** (boost `exercise_name`, `muscle_groups_activated`, etc.), l'évaluation *LLM-as-judge*, le monitoring Grafana, backend Postgres. Excellent modèle pédagogique de bout en bout. (GitHub)
- [GeorgiosLymperis/fitness_app](#) : plateforme analytics + coaching IA avec RAG, SQL backend (repository pattern), calcul de volume et **1RM estimé**, « coaching and diet rules via RAG », agents avec *tool calling* (SmolAgents). **Très proche de votre besoin**. (GitHub)
- [ChahineBA/Nutrition-RAG-LLM](#) : RAG sur le manuel *Human Nutrition (2020)*, pipeline chunking + embeddings (sentence-transformers) + vector DB (FAISS/Pinecone). Bon exemple pour ingérer un document scientifique long. (GitHub)
- [pramod-zillella/RAG-Fitness-Coach](#) : RAG sur contenu vidéo (transcriptions), Pinecone + Gemini. (GitHub)
- [SayamAlt/Personalized-Health-and-Fitness-Coach-using-Langchain](#) : **routage multi-experts** via `MultiPromptChain` (nutritionniste / expert fitness / thérapeute) — directement

pertinent pour votre architecture « sous-agents » nutrition vs musculation. (GitHub)

- (shubh-vedi/fitness_chatbot_LLM): chatbot avec base d'exercices + LLM (Streamlit, Pandas). (GitHub)
- Sur **GitHub Topics** ((fitness), (ai-coach)), plusieurs projets récents combinent explicitement **Next.js + Supabase + RAG + Claude/Claude Code** pour du coaching fitness (tags (supabase) + (fitness) + (rag) + (claude-code)) — à parcourir pour des patterns d'architecture à jour. (GitHub)

Recommandations

Étape 1 — Socle de données (à faire en premier) :

1. Charger **CIQUAL** (dump XML/Excel de la dernière version → tables Supabase) comme référence nutritionnelle française. C'est votre **source de vérité** pour les aliments bruts. Transposez la structure relationnelle ((alim), (const), (compo)).
2. Charger **Free Exercise DB** (JSON/NDJSON → table Supabase) comme bibliothèque d'exercices. Traduire noms/instructions en français **par batch en pré-traitement une seule fois** (via LLM), pas à l'exécution.
3. Activer **pgvector** sur Supabase pour indexer ces données + les fiches de synthèse scientifique pour le RAG.

Étape 2 — Données dynamiques : 4. Intégrer **Open Food Facts** par **appel API par code-barres** avec **cache agressif en base** (les fiches produit changent peu). Réservez-le aux produits emballés que l'utilisateur scanne/saisit. 5. Optionnel : clé **USDA** en complément pour micronutriments détaillés ou aliments manquants.

Étape 3 — Calculs déterministes : 6. Coder **Mifflin-St Jeor** (BMR/TDEE), les **ratios de macros**, et **Epley/Brzycki** (1RM) en TypeScript. Les exposer comme *tools/functions* appelés par le LLM — **ne jamais laisser le LLM calculer**.

Étape 4 — Base de connaissance scientifique (RAG + prompt système) : 7. Résumer les points-clés des position stands ISSN (protéines, timing, diètes) et des repères ANSES en **fiches condensées markdown**, les chunker et les indexer pour le RAG. Injecter un **résumé court** dans le prompt système de chaque sous-agent (pas les PDF entiers). 8. Citer les sources (ISSN 2017, ANSES 2016) dans les réponses pour la traçabilité.

Étape 5 — Architecture sous-agents : 9. S'inspirer de (fitness_app) (GeorgiosLymperis) pour les « diet/coaching rules via RAG » et de (SayamAlt) (MultiPromptChain) pour le **roulage multi-experts** nutrition/musculation.

Seuils qui feraient évoluer ces recommandations :

- Si vous dépassez ~10 req/min en recherche (ou 100 req/min en lookup produit) sur Open Food Facts → basculer sur le **dump complet local** (Parquet/CSV).

- Si vous avez besoin d'exercices avec **GIFs animés** → ExerciseDB tier gratuit auto-hébergé plutôt que Free Exercise DB (images statiques).
- Si l'app devient **multi-utilisateurs** → mettre en cache/local tout ce qui passe par API pour éviter les rate limits et les coûts.

Caveats

- **Licences** (à respecter, notamment l'attribution) : CIQUAL (open data ANSES), Open Food Facts (**ODbL**, attribution + share-alike), USDA (**CC0**, totalement libre), Free Exercise DB (**domaine public**, libre), wger (données **CC-BY-SA**, attribution + partage à l'identique, à vérifier par exercice). ([Openfoodfacts](#)) ([Formula Bot](#))
- **Qualité crowdsourcée vs validée** : Open Food Facts et wger contiennent des données saisies par la communauté — **non garanties exactes**. CIQUAL et USDA sont validées scientifiquement (laboratoire, méthodes reconnues). Privilégiez CIQUAL/USDA pour les affirmations factuelles. ([Anses](#))
- **Recommandations générales vs performance** : les repères ANSES visent la santé publique, pas l'optimisation musculation. Les position stands ISSN sont plus adaptés, mais **certains auteurs déclarent des conflits d'intérêts** (financements de l'industrie des suppléments, notamment sur la créatine) — à garder en tête et à mentionner si vous citez ces sources. ([Taylor & Francis Online](#))
- **Les formules sont des estimations** : Mifflin-St Jeor perd en précision pour les sujets très musclés, un IMC > 35 ou les plus de 65 ans ; les formules 1RM sont fiables à 1-10 reps et divergent au-delà. **Toujours ajuster selon les résultats réels** (poids réel suivi sur 2-3 semaines, ± 100 kcal/jour). ([Promealplan](#))
- **Pas de dataset ouvert de « courbes de force »** standardisées : ces tables de standards sont propriétaires ; contentez-vous des calculs 1RM + %1RM.
- **CIQUAL n'a pas d'API officielle** : vous dépendez d'un dump local (recommandé) ou de wrappers communautaires non officiels (kozlown, zzgael) dont la maintenance et la fraîcheur des données ne sont pas garanties.
- **wger : nombre d'exercices approximatif** (~700 base, chiffre à re-vérifier en live via le champ `count` de l'API) et **aucune limite de débit publique documentée** — un vide à surveiller si vous vous appuyez sur l'API live plutôt que sur un dump.
- Les projets GitHub cités sont des **inspirations architecturales**, pas des solutions clés en main ; leur qualité, licence et maintenance varient — auditez avant de réutiliser du code.